

บท 8 การแบ่งกลุ่ม (Clustering Analysis):

Classifier (การจำแนกประเภท) เป็นการเรียนรู้แบบมีผู้สอน (Supervised Learning) ที่ต้องใช้ ข้อมูลที่มีป้ายกำกับ (Labeled Data) โมเดลจะเรียนรู้จากข้อมูลตัวอย่างที่ถูกกำหนดหมวดหมู่ไว้แล้ว จากนั้นใช้ในการจำแนกข้อมูลใหม่ให้อยู่ในกลุ่มที่ต้องการ

Clustering (การจัดกลุ่ม) เป็นการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) โดยโมเดลจะวิเคราะห์และจัดกลุ่มข้อมูลที่มีลักษณะคล้ายกันโดยอัตโนมัติ โดยไม่ต้องกำหนดหมวดหมู่ล่วงหน้า

แตกต่างกันที่การจัดกลุ่ม โดย Clustering จะแบ่งกลุ่มข้อมูลจากความคล้าย โดยไม่มีการกำหนดประเภทข้อมูลไว้ก่อนหรือเราไม่ทราบจำนวนกลุ่มล่วงหน้า เป็นการเรียนรู้แบบไม่มีผู้สอน ส่วนการจัดกลุ่มแบบ Classifier มีการกำหนดประเภทข้อมูลล่วงหน้าเพื่อนำมาฝึกโมเดลให้สามารถทำนายกลุ่มที่เหมาะสมได้ เป็นการเรียนรู้แบบมีผู้สอน

-อาจารย์จะให้พวกค่าเฉลี่ยมาแล้วนำมา Analysis
ดูตัวอย่างจากเสีย BlueTspace

Cluster 1	Min	Max	Average
Age	17	90	46
Gender	0	1	1
SMS	0	10	2.7
Phone	102	200	152

กลุ่มที่ 1 เป็นกลุ่มคนที่ช่วงอายุ 46 และเป็นผู้ชาย มีการโทรมากกว่าใช้ SMS


Cluster 2	Min	Max	Average
Age	17	88	48
Gender	0	1	1
SMS	0	20	7.5
Phone	15	98	45.3

กลุ่มที่ 2 เป็นกลุ่มคนที่ช่วงอายุ 48 และเป็นผู้ชาย มีการโทรมากกว่าใช้ SMS แต่ใช้น้อยกว่ากลุ่มที่ 1

Cluster 3	Min	Max	Average
Age	17	91	45
Gender	0	1	1
SMS	0	100	34
Phone	0	24	8.3

กลุ่มที่ 3 เป็นกลุ่มคนที่ช่วงอายุ 45 และเป็นผู้ชาย มีการใช้ SMS มากกว่าการโทร

Elbow Method คือ เทคนิคการหาจำนวน cluster ที่เหมาะสม โดยดูจากจุดที่กราฟแสดงการเปลี่ยนแปลงที่ช้าลง



บท 7 **Bayesian Theorem (ทฤษฎีของเบย์)** การใช้ทฤษฎี: ทฤษฎีของเบย์เป็นหลักการคำนวณความน่าจะเป็นที่ใช้ในการอัปเดตความน่าจะเป็นของสมมติฐาน (เช่น เหตุการณ์) เมื่อมีข้อมูลใหม่เข้ามา

สมมติฐาน: ในทฤษฎีของเบย์ เราจะใช้ข้อมูลที่มีอยู่แล้วเพื่อปรับความน่าจะเป็นของสมมติฐาน เช่น ถ้าคุณมีข้อมูลเกี่ยวกับโรคเมะเร็ง และผลการตรวจ, คุณสามารถคำนวณได้ว่า ความน่าจะเป็นที่คนไข้จะเป็นมะเร็งจริง ๆ เมื่อผลตรวจเป็นบวก

การคำนวณ: ใช้สูตร $P(h|D) = P(D|h) \cdot P(h) / P(D)$ ที่อธิบายถึงความน่าจะเป็นที่สมมติฐาน h จะเป็นจริงเมื่อได้รับข้อมูล D โดยคำนึงถึงความน่าจะเป็นก่อนหน้า ($P(h)$) และข้อมูล ($P(D)$) ที่มี $P(h)$: ความน่าจะเป็นของสมมติฐาน h ก่อนที่ข้อมูล D จะมา

$P(D)$: ความน่าจะเป็นของข้อมูล D

$P(h|D)$: ความน่าจะเป็นที่สมมติฐาน h เป็นจริงเมื่อได้รับข้อมูล D = $\frac{P(D|h)P(h)}{P(D)}$

$P(D|h)$: ความน่าจะเป็นที่ข้อมูล D จะเกิดขึ้นเมื่อสมมติฐาน h เป็นจริง

ตัวอย่าง การเกิดโรคมะเร็ง (Cancer)

ยกตัวอย่างโรคระบาด: ผลการตรวจเป็นบวก (+) อาการกราวว่า เราควรระวังภัยโรคระบาดไหมว่าเป็นเรื่องจริงหรือไม่? ความน่าจะเป็นคือ

- ผลการตรวจเป็นบวกจะให้ความถูกต้อง 98% กรณีที่มีโรคมะเร็งอยู่จริง
- ผลการตรวจเป็นลบจะให้ความถูกต้อง 97% กรณีที่ไม่มีโรคมะเร็ง
- 0.008 ของประชากรทั้งหมดเป็นโรคมะเร็ง

จากความน่าจะเป็นข้างต้น เราทราบค่าความน่าจะเป็นต่อไปนี้

$$\begin{aligned} \text{เป็นมะเร็ง } P(\text{cancer}) &= 0.008 & \text{ไม่เป็น } P(\sim\text{cancer}) &= 0.992 \\ \text{+ เป็นจริง } P(+ | \text{cancer}) &= 0.98 & P(- | \text{cancer}) &= 0.02 \\ P(+ | \sim\text{cancer}) &= 0.03 & P(- | \sim\text{cancer}) &= 0.97 \end{aligned}$$

ตัวอย่าง การเกิดโรคมะเร็ง (Cancer)

เราสามารถคำนวณค่าความน่าจะเป็นของสมมติฐานว่าคนไข้เป็น / ไม่เป็นโรคมะเร็ง เมื่อทราบผลตรวจเป็นบวก โดยใช้กฎของเบย์ ดังนี้

ความน่าจะเป็นที่คนไข้จะเป็นโรคมะเร็งเมื่อผลตรวจเป็นบวก เท่ากับ

$$P(\text{cancer} | +) = \frac{P(+|\text{cancer})P(\text{cancer})}{P(+)} = \frac{(0.98) \cdot 0.008}{(0.03) \cdot 0.008 + 0.992 \cdot 0.03}$$

ความน่าจะเป็นที่คนไข้จะไม่เป็นโรคมะเร็งเมื่อผลตรวจเป็นบวก เท่ากับ

$$P(\sim\text{cancer} | +) = \frac{P(+|\sim\text{cancer})P(\sim\text{cancer})}{P(+)} = \frac{(0.03) \cdot 0.992}{(0.03) \cdot 0.008 + 0.992 \cdot 0.03}$$

ความน่าจะเป็นที่คนไข้จะเป็นมะเร็ง หลังจากผลการตรวจออกมาเป็นบวก:

$P(h)$ คือ ความน่าจะเป็นที่คนไข้จะเป็นมะเร็ง (สมมติว่า 0.01 หรือ 1% ของประชากรเป็นมะเร็ง)

$P(D|h)$ คือ ความน่าจะเป็นที่ผลการตรวจจะเป็นบวก หากคนไข้เป็นมะเร็ง (สมมติว่า 98%)

$P(D)$ คือ ความน่าจะเป็นที่จะได้ผลบวก (รวมทั้งผู้ที่เป็นและไม่ใช่เป็นมะเร็ง)

ตัวอย่าง ผิวไหม้ (Sunburn)

Sample	Hair color	Eye Color	Weight	Apply lotion	Sun burn
51	black	dark	overweight	No	-
52	red	dark	normal	No	-
53	Blonde	light	Overweight	No	-
54	Red	light	underweight	No	+
55	Black	dark	Overweight	Yes	-
56	Blonde	dark	Overweight	No	+
57	Red	light	underweight	Yes	-
58	Black	dark	Normal	No	-
59	Blonde	dark	Normal	Yes	+
60	Red	light	Normal	Yes	+
61	Black	light	Underweight	Yes	+
62	Blonde	light	Underweight	No	+
63	Red	dark	Normal	Yes	+
64	black	light	underweight	no	-

ความแตกต่างหลัก: สมมติฐานเกี่ยวกับความสัมพันธ์ของตัวแปร:

Bayesian Theorem: ไม่มีสมมติฐานเกี่ยวกับความสัมพันธ์ของตัวแปร โดยการคำนวณจะพิจารณาความสัมพันธ์ของตัวแปรทุกตัวที่เกี่ยวข้อง **Naïve Bayesian Learning:** สมมติว่าตัวแปรทุกตัวเป็นอิสระจากกัน ซึ่งทำให้คำนวณได้ง่ายขึ้นการใช้งาน: **Bayesian Theorem:** ใช้สำหรับกราคำนวณความน่าจะเป็นโดยพิจารณาข้อมูลทั้งหมดและความสัมพันธ์ระหว่างข้อมูล **Naïve Bayesian Learning:** ใช้สำหรับการทำนายหรือจำแนกประเภทเมื่อข้อมูลมีหลายปัจจัยที่อิสระจากกัน **Bayesian Theorem:** มีความซับซ้อนมากกว่า เนื่องจากต้องคำนึงถึงความสัมพันธ์ระหว่างตัวแปรต่าง ๆ

Naïve Bayesian Learning: คำนวณง่ายขึ้นเพราะสมมติว่าตัวแปรทุกตัวเป็นอิสระจากกัน **สรุป: Bayesian Theorem:** ใช้ในการคำนวณความน่าจะเป็นโดยไม่สมมติว่าตัวแปรต่าง ๆ เป็นอิสระจากกัน

Naïve Bayesian Learning: ใช้หลักการเดียวกับทฤษฎีเบย์ แต่สมมติว่าตัวแปรทุกตัวเป็นอิสระจากกันเพื่อให้การคำนวณง่ายขึ้น

ตัวอย่าง การเกิดเฮอริเคน


การพยากรณ์อากาศ (Weather forecast)

- ความน่าจะเป็นที่เฮอริเคนจะเกิดคือ 0.008
- กอบมีทักษะในการพยากรณ์ถูกต้องประมาณ 98% ของการทำนายทั้งหมด (Predict-hur)
- แต่กอบก็มีการทำนายถูกว่าไม่เกิดเฮอริเคนถูกต้อง 97% เช่นกัน (Predict-nohur)

$$P(\text{hurricane}) = 0.008 \quad P(\sim\text{hurricane}) = 0.992$$

$$P(\text{predict-hur} | \text{hurricane}) = 0.98$$

$$P(\text{predict-nohur} | \text{hurricane}) = 0.02$$



ตัวอย่าง การเกิดเฮอริเคน

ถ้าสุ่มวันขึ้นมา จากทักษะที่กอบทำนายการเกิดเฮอริเคน จะเชื่อเขาหรือไม่??

$$P(\text{hurricane}) = 0.008 \quad P(\sim\text{hurricane}) = 0.992$$

$$P(\text{predict-hur} | \text{hurricane}) = 0.98 \quad P(\text{predict-hur} | \sim\text{hurricane}) = 0.03$$

$$P(\text{predict-nohur} | \text{hurricane}) = 0.02 \quad P(\text{predict-nohur} | \sim\text{hurricane}) = 0.97$$

ความน่าจะเป็นที่เขาทำนายถูกต้อง?

$$P(\text{hurricane} | \text{predict-hur}) = \frac{P(\text{predict-hur} | \text{hurricane})P(\text{hurricane})}{P(\text{predict-hur})} = \frac{0.98 \cdot 0.008}{0.98 \cdot 0.008 + 0.03 \cdot 0.992} = 0.0078$$

ความน่าจะเป็นที่เขาทำนายผิด?

$$P(\sim\text{hurricane} | \text{predict-hur}) = \frac{P(\text{predict-hur} | \sim\text{hurricane})P(\sim\text{hurricane})}{P(\text{predict-hur})} = \frac{0.03 \cdot 0.992}{0.98 \cdot 0.008 + 0.03 \cdot 0.992} = 0.0298$$

การเรียนรู้แบบอย่างง่าย (Naïve Bayesian Learning)

วิธีการของ Naïve Bayesian คือการให้วิธีการของเบย์พร้อมสมมติฐานของการเป็นอิสระต่อกันของตัวแปรอิสระทุกตัว

โดยถ้า: instance x มี n แอททริบิวต์ หรือ $x = (A_1, \dots, A_n)$ และ มี Ci เป็น class label

$$\text{Naïve Bayes Classifier} = \text{Max}_i \frac{P(C_i) \prod_{j=1}^n P(A_j | C_i)}{P(A_1, \dots, A_n)}$$

$$C = \text{Max}_{i=1}^n P(C_i) \prod_{j=1}^n P(A_j | C_i)$$

ตัวอย่าง ผิวไหม้ (Sunburn)

- Instance x = <hair color= red, eye color = dark, weight= overweight, apply lotion = no>

เพราะฉะนั้น เมื่อ instance ใหม่เข้ามาถามว่า ผิวจะไหม้หรือไม่

$$C_1 : \text{sun burn is +} = P(+ | \text{red}) \cdot P(\text{dark} | +) \cdot P(\text{overweight} | +) \cdot P(\text{apply lotion} | +)$$

$$= \frac{9}{14} \cdot \frac{3}{9} \cdot \frac{2}{9} \cdot \frac{6}{9} = 0.01$$

$$C_2 : \text{sun burn is -} = P(- | \text{red}) \cdot P(\text{dark} | -) \cdot P(\text{overweight} | -) \cdot P(\text{apply lotion} | -)$$

$$= \frac{5}{14} \cdot \frac{2}{9} \cdot \frac{4}{9} \cdot \frac{2}{9} = 0.018 \quad \checkmark X \text{ belongs to class "sunburn" = "+"}$$

บท 6 K-NN Model (K-Nearest Neighbor) K-NN เป็นอัลกอริทึมการจำแนกประเภท (Classification) ที่ใช้หลัก "เพื่อนบ้านที่ใกล้ที่สุด" ในการตัดสินใจว่าข้อมูลใหม่ควรถูกจัดอยู่ในกลุ่มใด

หลักการทำงาน
-> กำหนดค่า k (จำนวนเพื่อนบ้านที่ใกล้ที่สุด), หาค่าระยะทาง ระหว่างข้อมูลใหม่กับข้อมูลเดิม (เช่น ใช้ Euclidean Distance), เลือก k จุดที่ใกล้ที่สุด, โหวตหากลุ่มที่มีมากที่สุด → กำหนดประเภทของข้อมูลใหม่

ตัวอย่างง่ายๆ ถ้ามีข้อมูลรูปสัตว์ที่ถูกแบ่งเป็น "แมว" 🐱 และ "สุนัข" 🐶

ถ้าคุณเพิ่มรูปใหม่ และ K-NN พบว่าใน k เพื่อนบ้านมีแมวเยอะกว่า → ระบบจะจัดเป็น แมว 🐱

ถ้าเจอ สุนัขเยอะกว่า → ระบบจะจัดเป็น สุนัข 🐶

1-NN (x_1) = กล้อง (Camera) $d(x_1, x_1) = \sqrt{(0-1)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2} = 2$

3-NN (x_1, x_3, x_5) = เครื่องสำอาง (Cosmetic) $d(x_1, x_3) = \sqrt{(0-0)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2} = 1.73$

5-NN (x_1, x_2, x_3, x_4, x_5) = กล้อง (Camera) $d(x_1, x_2) = \sqrt{(0-0)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2} = 1.73$

คลิกโฆษณา (Click Adr) = กล้อง (Camera) # $d(x_1, x_4) = \sqrt{(0-1)^2 + (0-0)^2 + (0-1)^2 + (0-1)^2} = 1.73$

$d(x_1, x_5) = \sqrt{(0-1)^2 + (0-1)^2 + (0-0)^2 + (0-0)^2} = 1.41$

Quiz พฤติกรรมคนใช้ Facebook


Sex	Occupation	Checkin	TypeOfPost	ClickAds
Male	Student	Education	Text	Camera
Female	Student	Bar	Video	Cosmetic
Female	Student	Bar	Text	Cosmetic
Male	Programmer	Bar	Text	Camera
Male	Student	Travel	Live	Camera

New instance $x_1 = \langle \text{Female, Programmer, Travel, Live, ClickAds} \rangle$

Use $k=1, 3$ or 5

K-NN Recommendation : แนะนำสิ่งที่ใกล้เคียงกับความชอบหรือพฤติกรรมของผู้ใช้ โดยใช้แนวคิดของ ความคล้ายคลึงกัน แบ่งเป็น 2 ประเภท

1. **Content-Based Filtering** แนะนำตามคุณสมบัติของไอเท็ม (เช่น หอมดอกไม้, คำอธิบาย, นักแสดง) เช่น ถ้าคุณดูหนังแอ็กชัน แนะนำหนังแอ็กชันเรื่องอื่น อย่างในภาพ user ชอบไวน์ ก็จะแนะนำไวน์ที่ features ที่มีรสชาติ อะไรคล้ายๆกัน



รูปของ Content-Based Filtering

2. **Collaborative Filtering** แนะนำตามพฤติกรรมของผู้ใช้คนอื่นที่คล้ายกัน เช่น ถ้าคุณดูหนังที่คนที่มีพฤติกรรมคล้ายกันชอบดู ก็แนะนำหนังที่พวกเขาชอบ อย่างในภาพ user 1 ชอบชอบไวน์ น้ำแข็ง กาแฟ แต่ user 2 ชอบเบียร์ ด้วยซึ่งก็จะแนะนำเบียร์ให้กับ user 1 ที่มีความชอบคล้ายกับ user 2



สรุป

Content-Based Filtering → วิเคราะห์คุณสมบัติของไอเท็ม,
Collaborative Filtering → วิเคราะห์พฤติกรรมของผู้ใช้

Collaborative Filtering แบ่งได้อีก 2 แบบคือ 1. **User-Based Filtering** ค้นหาผู้ใช้ที่มีพฤติกรรมคล้ายกัน ใช้ข้อมูลจากกลุ่มผู้ใช้ที่มีรสนิยมคล้ายกับเรา เพื่อแนะนำสิ่งที่พวกเขาชอบให้กับเรา

Netflix → ถ้าคุณและ "User A" เคยดูหนังหลายเรื่องเหมือนกัน ถ้า "User A" ดู "The Matrix" แต่คุณยังไม่เคยดู → ระบบจะแนะนำให้คุณดู

2. **Item-Based Filtering** ค้นหาไอเท็มที่มักถูกเลือกพร้อมกัน หรือมีความคล้ายคลึงกัน แนะนำสิ่งที่คล้ายกับสิ่งที่ผู้ใช้เคยเลือก

Shopee/Lazada → ถ้าคนที่ซื้อ "iPhone" มักซื้อ "AirPods" ด้วย ถ้าคุณซื้อ "iPhone" → ระบบจะแนะนำ "AirPods"

บท 9 Deep Learning :เป็นเทคโนโลยีปัญญาประดิษฐ์ที่ใช้ โครงข่ายประสาทเทียม (Artificial Neural Network - ANN) ที่มีหลายชั้น เพื่อให้คอมพิวเตอร์สามารถเรียนรู้และเข้าใจข้อมูลได้ดีขึ้น เหมือนสมองของมนุษย์ เช่น รถไร้คนขับ

Artificial Neural Network:คือคอมพิวเตอร์ที่สามารถเลียนแบบการทำงานของสมองมนุษย์ได้ ด้วยการประมวลผลข้อมูลสารสนเทศ และองค์ความรู้ได้ในคราวละมากๆเป็นการรวมกลุ่มแบบขนานของหน่วยประมวลผลย่อยๆทำให้เกิดความฉลาดของข่ายงาน เช่น คาดการณ์ยอดขาย || Deep Learning ต่างจาก Artificial Neural Network (ANN)อย่างไร 1.ANN มีจำนวนชั้น (Layers)ที่น้อยกว่าโดยมี 1-2ชั้นแต่ DeepLearningมี3ชั้นขึ้นไป 2.ANN สามารถทำงานข้อมูลที่ง่ายๆไม่ซับซ้อนเช่นแยกตัวเลข แต่Deepสามารถวิเคราะห์ข้อมูลซับซ้อนได้ เช่นการรู้จำภาพจำเสียง 3.ANNต้องให้มนุษย์ช่วยออกแบบคุณสมบัติข้อมูล ส่วนDeepสามารถเรียนรู้คุณสมบัติจากข้อมูลเองได้อัตโนมัติ || Image Auggmentation With ImageDataGenerator

Image shift = การเคลื่อน

Image flip = กลับทางสลับ

Image rotation = การหมุน

image brightness เพิ่ม

Image zoom = การซูม

Single-layer Perceptron :: SLP

Multi-layer Perceptron :: MLP

x1	x2	y
humidity	Rain	Growth
0	0	0
0	1	0
1	0	0
1	1	1

กำหนด

 $w_1 = 0.5$
 $w_2 = 2.5$
 $\theta = 1.0$
 $\alpha = 0.2$

humidity(x_1) $\cdot w_1 = 0.5$

rain(x_2) $\cdot w_2 = 2.5$

$y = \begin{cases} 1 & \text{if } w_1x_1 + w_2x_2 - \theta \geq 0 \\ 0 & \text{if } w_1x_1 + w_2x_2 - \theta < 0 \end{cases}$

$\hat{y} = f(w_1x_1 + w_2x_2 - \theta)$

$\epsilon = y - \hat{y}$

$\Delta w_1 = \alpha(y - \hat{y})x_1$

$\Delta \theta = -\alpha(y - \hat{y})$

$w_{new} = w_{old} + \Delta w$

$\theta_{new} = \theta_{old} + \Delta \theta$

```
# Train the model
epochs = 10 # Adjust the number of epochs as needed
history = model.fit(train_images, validation_data=val_images, epochs=epochs)
```

```
train_generator = tf.keras.preprocessing.image.ImageDataGenerator(
    rescale=1./255,
    horizontal_flip=True,
    width_shift_range=0.2,
    height_shift_range=0.2,
    validation_split=0.1
)

test_generator =
```

```
val_images = train_generator.flow_from_dataframe(
    dataframe=train_df,
    x_col='filepath',
    y_col='label',
    target_size=(224, 224),
    color_mode='rgb',
    class_mode='categorical',
    batch_size=32,
    shuffle=True,
    seed=42,
    subset='validation'
)
```

train_image และ test_image